

张量手册

Thomas Dybdahl Ahle

2026 年 6 月 16 日

第一章 引言

这是什么？ 这些页面是一本张量导览，使用“张量图”的视觉语言。为了展示这种方法的普适性，我尽量紧跟传奇的《Matrix Cookbook》。因此，正文大多是关于张量及其相关内容的一组事实（恒等式、近似、不等式、关系，等等）。你不会在这里看到太多原始手册之外的结果，但希望这些图示能为你提供一种新的理解和欣赏方式。

这是一个持续进行的项目： 《Matrix Cookbook》是一本很长的书，并不是每一部分都同样适合用图示表达。因此我选择跳过某些部分，并缩短另一些部分。也许将来，我或其他人会进一步扩展覆盖范围。

例如，我们覆盖了关于线性组合的期望和高斯矩的全部结果，但跳过了一般多元分布那一节。我也不得不稍微重排材料，以避免一开始就把所有记号都介绍完。

复数矩阵与协方差 张量图（或张量网络）目前最常见于量子物理，但这不是一本给物理学家的书。《Matrix Cookbook》是一本给工程师的书，尤其是机器学习领域，而在这里复数并不常见。没有复数，我们就不必担心复共轭，这简化了转置，也去掉了协变与逆变张量的需要。如果你是物理学家，你大概更需要一本关于张量分析的书。

Tensorgrad 张量图的符号化特性使它们非常适合符号计算。

张量图记号的优点： 与其他记号相比，张量图记号有很多好处：

诸如迹、张量积或张量缩并之类的操作，都可以不借助额外记号而直接表达。指标和张量的名称往往可以省略。这既省时又简化记号，尤其适合那些主要只是用于求和的内部指标。复杂缩并网络所得到张量的阶数可以一眼看出：它就是未配对连线的数量。比如，一个所有连线都接上的张量网络，无论多复杂，结果都必然是一个标量。

词源 “tensor”一词源自拉丁语 *tensio*，意为“张力”或“伸展”，又来自动词 *tendere*，意为“拉伸”或“延展”。它最早在 19 世纪中叶由 William Rowan Hamilton 在四元数

研究中引入数学语境，当时它指的是四元数的模长。后来 Gregorio Ricci-Curbastro 和 Tullio Levi-Civita 在发展张量微积分时确立了“tensor”的现代用法；这套框架把标量、向量和矩阵的概念推广到了更复杂的多维对象。[1, 2].

目录

第一章 引言	1
1.1 张量图	5
1.2 复制张量	6
1.3 张量求和	7
1.4 转置	8
1.4.1 高阶情形	9
1.5 迹	9
1.5.1 高阶迹	9
1.6 特征值	10
1.7 对称与对称化	10
1.8 协变与逆变	11
1.9 练习	11
第二章 统计与概率	12
2.1 矩的定义	12
2.1.1 线性组合的期望	12
2.1.2 线性形式	13
2.1.3 二次型	13
2.1.4 三次型	14
2.2 累积量	15
2.2.1 四次型	16
2.3 加权标量变量	17
2.4 高斯矩	17
2.4.1 高斯分部积分	17
2.4.2 三次型	18
2.4.3 四次型的均值	18

目录	4
2.4.4 高斯混合	19
2.4.5 导数	20
2.5 向量与张量的自由概率	20
2.5.1 向量的自由累积量	20
2.5.2 矩阵的自由累积量	21
2.5.3 张量自由累积量	22
2.5.4 张量 Wick 定理	23
2.5.5 张量自由性下的可加性	24
2.5.6 张量 Wishart 矩阵的谱	25
2.5.7 张量网络与自由概率	25
2.5.8 高阶张量示例	26
2.5.9 D 元 Catalan 数	27
2.5.10 Melon 型图	28
2.6 练习	29
第三章 机器学习应用	31
3.1 最小二乘	31
3.2 交叉熵损失的 Hessian 矩阵	31
3.3 卷积神经网络	31
3.4 Transformer / 注意力	31
3.5 张量草图	31
3.6 强化学习	31
第四章 附录	33

1.1 张量图

张量图是简单的图（或“网络”），其中节点表示变量（例如向量或矩阵），边表示缩并（例如矩阵乘法或内积）。下表展示了一些基本操作如何用张量图写出：

点积	$a-b$	$y = \sum_i a_i b_i$	$[\cdots] \begin{bmatrix} \cdot \\ \cdot \\ \cdot \end{bmatrix}$	$= y$
外积	$-a \quad b-$	$Y_{i,j} = a_i b_j$	$\begin{bmatrix} \cdot \\ \cdot \\ \cdot \end{bmatrix} [\cdots]$	$= -Y-$
矩阵-向量	$-A-b$	$y_i = \sum_j A_{i,j} b_j$	$\begin{bmatrix} \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \end{bmatrix} \begin{bmatrix} \cdot \\ \cdot \\ \cdot \end{bmatrix}$	$= -y$
矩阵-矩阵	$-A-B-$	$Y_{i,k} = \sum_j A_{i,j} B_{j,k}$	$\begin{bmatrix} \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \end{bmatrix} \begin{bmatrix} \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \end{bmatrix}$	$= -Y-$

我们把向量和矩阵看作 1 阶和 2 阶张量。阶数对应于上面 $[\cdots]$ 可视化中的维数，例如，向量是一维的数字列表，而矩阵是二维的数字网格。阶数也决定了张量图中表示该变量的节点的度数。

当我们处理 3 阶及更高阶张量时，图记号会变得更有趣。一个 3 阶张量可以看作一个数字立方体，或者一叠矩阵。例如，我们可以把它写成 $T \in \mathbb{R}^{n \times m \times k}$ ，于是对 $i = 1 \dots n$ ， $T_i \in \mathbb{R}^{m \times k}$ 是一个矩阵。当然，我们也可以沿其他轴切分 T ，因此 $T_{:,j} \in \mathbb{R}^{n \times k}$ 和 $T_{:, :, \ell} \in \mathbb{R}^{n \times m}$ 也都是矩阵。

矩阵有两条伸出的边，意味着可以用两种方式让向量与它相乘：从左边乘，即 $x^T M$ ；或者从右边乘，即 Mx 。在图记号中，我们只写作 $x-M-$ 和 $-M-x$ 。3 阶张量有三条边，因此可以用三种方式让它与一个向量相乘：

$$\begin{array}{c} | \\ T \\ \swarrow \searrow \end{array} x \quad \text{和} \quad x \begin{array}{c} | \\ T \\ \swarrow \searrow \end{array} \quad \text{和} \quad \begin{array}{c} x \\ | \\ T \\ \swarrow \searrow \end{array}$$

要完全精确地说明每一种写法的含义，我们应该给边加上标签。例如，我们会写成 $\begin{array}{c} | \\ T \\ \swarrow \searrow \end{array} x$ 来表示矩阵 $\sum_i T_i x_i$ 。不过，相关的边通常能从上下文中看出；这正是张量图记号比 Einstein 求和记号更清爽的原因之一。

$$Y_{i,j} = \sum_{k,l,m,n,o} A_{i,k} B_{l,n,o} C_{j,k,l,m} D_{m,n} E_o \Leftrightarrow \begin{array}{c} i \\ \swarrow \\ j \end{array} Y = \begin{array}{c} i \\ \swarrow \\ A \\ k \end{array} \begin{array}{c} l \\ \swarrow \\ B \\ n \end{array} \begin{array}{c} o \\ \swarrow \\ E \end{array} \begin{array}{c} j \\ \swarrow \\ C \\ m \end{array} \begin{array}{c} D \end{array}$$

张量图的核心原则是：边缩并满足结合律。这意味着你可以按任意喜欢的顺序缩并任意边。从上面的求和表示也能看出这一点，因为其中对 k, l, m, n 的求和可以按任意顺序重排。

不同缩并顺序的计算代价可能相差很大。遗憾的是，寻找最优顺序在计算上并不容易。关于寻找最佳缩并顺序的算法以及近似缩并方法，见第 ?? 节。

注意，张量图并不总是连通的。我们已经看到，两个向量的外积可以写成 $-a \ b-$ 。从求和表示来看这很自然：没有边就意味着没有求和。因此这里 $y_{i,j} = a_i b_j$ ，这正是外积 $y = a \otimes b$ 。

1.2 复制张量

一个特别重要的张量是“复制”张量，也称为“对角”张量、“Kronecker delta”张量或“spider”张量。最简单的版本是全 1 向量，我们把它写作 $\circ-$ 。也就是说 $\circ_i = 1$ 。一般的 n 阶版本在对角线上取值为 1，在其他位置取值为 0：

$$\circ_{i,j,k,\dots} = \begin{cases} 1 & \text{if } i = j = k = \dots \\ 0 & \text{otherwise} \end{cases}$$

或者，使用 Iverson 记号，¹ $\circ_{i,j,k,\dots} = [i = j = k = \dots]$ 。可以看到，2 阶复制张量 $-\circ- = I$ 只是单位矩阵，因此可以像这样直接从图中删去：

$$-A-\circ-B- = -A-B-$$

高阶复制张量非常有用，因为它们让我们能够把简单的张量图变成超图。一个简单的用法是表示对角矩阵 D_a ，它在对角线上是 a ，其他位置是 0。我们可以写成

$$D_a = \begin{array}{c} | \\ \circ \\ \swarrow \searrow \\ a \end{array}$$

为什么？因为 $(D_a)_{i,j} = \sum_k \circ_{i,j,k} a_k = \sum_k [i = j = k] a_k = [i = j] a_i$ 。类似地，Hadamard 积 $(a \circ b)_i = a_i b_i$ 可以写成

$$a \circ b = \begin{array}{c} | \\ \circ \\ \swarrow \searrow \\ a \quad b \end{array}$$

现在，让我们看看为什么大家都喜欢复制张量：用“复制张量操作”来证明恒等式 $D_a D_b = D_{a \circ b}$ ：

$$D_a D_b = \begin{array}{c} | \quad | \\ \circ - \circ \\ \swarrow \searrow \quad \swarrow \searrow \\ a \quad b \end{array} = \begin{array}{c} \swarrow \quad \swarrow \\ \circ \\ \searrow \quad \searrow \\ a \quad b \end{array} = \begin{array}{c} \swarrow \quad \swarrow \\ \circ \\ \searrow \quad \searrow \\ a \quad b \end{array} = D_{a \circ b}.$$

¹ 对一个逻辑命题 P ，我们定义 $[P] = \begin{cases} 1 & \text{if } P \\ 0 & \text{otherwise} \end{cases}$ 。

你可以用求和表示来验证这一点。

这里起作用的一般规则是：任何由复制张量组成的连通子图都可以合并成一个复制张量。有时我们甚至足够幸运，化简后还会留下一个可以删去的单位矩阵：

$$S \text{ --- } \text{---} \text{---} T \text{ ---} = S \text{ --- } T \text{ ---} = S \text{ --- } T \text{ ---}$$

唯一需要稍微小心的是结果张量为 0 阶的时候。根据你如何定义 0 阶复制张量 $\circ$ ，恒等式 $\circ - \circ = \circ$ 可能成立，也可能不成立。

在普通向量记号中许多需要特殊记号的构造（例如对角矩阵或 Hadamard 积），都可以用复制张量统一起来。在《Matrix Cookbook》中，他们定义了 4 阶张量 J ，它满足 $J_{i,j,k,l} = [i = k][j = l]$ ，我们会把它写成 $J = \text{---} \text{---}$ ，并且满足例如 $\frac{dX}{dX} = J$ 。使用“张量积”，你可以写成 $J = I \otimes I$ 。注意， J 不同于 4 阶复制张量 $\bowtie$ 。

1.3 张量求和

张量积可以表示任何线性函数。也就是说，满足 $f(ax, by) = abf(x, y)$ 的函数都可以这样表达。不幸的是，并非所有张量上的操作都是线性的。即使像两个向量之和 $x + y$ 这样简单的运算，也无法用一个简单的缩并图来表示。（注意这不是线性的，因为 $ax + by \neq ab(x + y)$ 。）

为了处理这个重要操作，Penrose 建议直接把两个图写在一起，中间加一个加号，例如 $-x + -y$ 。注意这本身仍然是 1 阶张量，尽管看起来像是有两条自由边。如果我们想把这个和与另一个张量相乘，可以用括号写成 $-M - (-x + -y)$ 。

在处理求和时使用命名边会很有帮助，这样更容易看清哪些边彼此对应。求和与张量积之间有很好的相互作用，满足一种广义的分配律：

$$\left(\begin{array}{c} \text{---}^i \\ \text{---}^k \\ \text{---}^j \end{array} \text{---} M \text{---}^k + \begin{array}{c} \text{---}^k \\ \text{---}^j \end{array} \text{---} V \right) = \begin{array}{c} \text{---}^i \\ \text{---}^k \\ \text{---}^j \end{array} \text{---} M \text{---}^k + \begin{array}{c} \text{---}^k \\ \text{---}^j \end{array} \text{---} V$$

当我们相加的张量边数不同，或者边名不同的时候，可以使用“广播 (broadcasting)”。假设我们想把一个矩阵 M 和一个向量 x 相加。这到底是什么意思？如果我们想把 x 加到 M 的每一行上，可以写成 $\frac{i}{j} M + \frac{i}{j} x$ 。这是因为 $\frac{i}{j} x$ 这是 x 与全 1 向量的外积，得到的是一个每一行都相同的矩阵。类似地，如果我们想把 x 加到每一列上，可以使用这个矩阵 $\frac{i}{j} x$ 。

注意，处理张量时我们通常不谈“行”或“列”，而只是使用张量的边名（有时也叫轴）。当使用命名边时，像“转置”这样的经典向量记号操作也可以去掉。矩阵 X^T 只是把左边和右边的边交换一下而已。但如果边已经命名，我们就根本不必再去追踪“边在什么位置”了。

1.4 转置

在经典矩阵记号中，转置会交换矩阵的指标，因此

$$(A^T)_{ij} = A_{ji}.$$

在张量图记号中，我们有两种选择，取决于是否要让边的位置具有意义。当边位置有意义时，我们通常让“左边”对应第一个指标，让“右边”对应第二个指标。因此转置就需要把边翻转：

$$(-A-)^T = \overline{\underbrace{A}} = -A^T-.$$

有些作者喜欢用把张量上下翻转的记号 $-V-$ ，作为交换左右边的更简洁写法。

在实际计算中，追踪边的位置很容易出错。更稳妥的做法是给张量的“输出”命名，并让转置去重命名这些边：

$$({}^i-A-j)^T = {}^{i-j}A-^i$$

重命名可以通过乘上单位矩阵来完成：

$$({}^i-A-j)({}_j-\circ-k) = {}^i-A^{j-k},$$

但必须小心，因为重叠的边名会让乘法失去结合性。例如：

$$[({}^i-A-j)({}_j-\circ-k)]({}_k-\circ-j) = {}^i-A-j \neq ({}^i-A-j)[({}_j-\circ-k)({}_k-\circ-j)] = {}^i-A-j \circlearrowright,$$

其中 $\circlearrowright$ 等于矩阵维数。在 Tensorgrad 中，我们通过要求任何一个边名在任意乘积中最多出现两次来解决这个问题。

为了转写《Matrix Cookbook》，使用“位置有意义”的记号更方便。我们注意到如下恒等式：

$$\begin{aligned} (A^T)^T &= A & \overline{\overline{A}} &= -A- \\ (A+B)^T &= A^T + B^T & \overline{(-A- + -B-)} &= \overline{-A-} + \overline{-B-} \end{aligned} \quad (4)$$

$$(AB)^T = B^T A^T \quad \overline{\overline{A-} \overline{B-}} = \overline{\overline{V-}}_{-B-} = -B-V- \quad (5)$$

1.4.1 高阶情形

可以把转置的思想推广到高阶张量。这要把边划分为“输入”和“输出”边，更常见地说，就是“逆变”边和“协变”边。关于这一点的更多内容，见本章末尾的小节。

如果 $A^T = A$ ，我们就说矩阵是对称的。对于高阶张量，对称的方式有很多种。更多内容见第 1.7 节。

1.5 迹

方阵的“迹”定义为 $\text{Tr}(A) = \sum_i A_{ii}$ 。在张量图记号中，这对应一条自环边：



。《Matrix Cookbook》中有一系列使用迹的恒等式。我们用张量图把它们重写出来：

$$\sum_{i=1}^n A_{ii} = \text{Tr}(A) = \text{Tr}(AI) \quad \text{Diagram: } \text{Circle with A and I} = \text{Diagram: } \text{Circle with A and a dot} \quad (11)$$

$$\text{Tr}(A) = \text{Tr}(A^T) \quad \text{Diagram: } \text{Circle with A} = \text{Diagram: } \text{Circle with V} \quad (13)$$

$$\text{Tr}(AB) = \text{Tr}(BA) \quad \text{Diagram: } \text{Circle with A-B} = \text{Diagram: } \text{Circle with B-A} = \text{Diagram: } \text{Circle with A and B} \quad (14)$$

$$\text{Tr}(A+B) = \text{Tr}(A) + \text{Tr}(B) \quad \text{Diagram: } \text{Circle with } (-A- + -B-) = \text{Diagram: } \text{Circle with A} + \text{Diagram: } \text{Circle with B} \quad (15)$$

$$\begin{aligned} \text{Tr}(ABC) &= \text{Tr}(BCA) & \text{Diagram: } \text{Circle with } A-B-C &= \text{Diagram: } \text{Circle with } B-C-A \\ &= \text{Tr}(CAB) & &= \text{Diagram: } \text{Circle with } C-A-B \end{aligned} \quad (16)$$

$$\begin{aligned} a^T a &= \text{Tr}(aa^T) & \text{Diagram: } a-a &= \text{Diagram: } \text{Circle with } (-a \ a-) \\ & & &= \text{Diagram: } \text{Circle with } a \ a \end{aligned} \quad (17)$$

1.5.1 高阶迹

对于高阶张量，我们仍然把迹定义为对角元素之和。也就是说，对于一个 n 阶张量 A ，迹就是它与 n 阶复制张量的乘积：

$$\text{Tr}(\underset{\nearrow}{T}) = \underset{\nearrow}{T} \text{Diagram: } \text{Circle with } T \text{ and a dot}.$$

在量子力学中，常会用到“部分迹”，我们可以用指标记号来定义：

$$\text{Tr}_{i,j}(\overset{|^k}{T}_{\underset{|}{i}\underset{|}{j}}) = \overset{|^k}{T}_{\bigcirc}.$$

当然，在张量图里，我们也可以不命名指标就使用部分迹。我们甚至不必去想所做的缩并到底是不是迹。

1.6 特征值

特征值和特征向量是线性代数中的基本概念，在张量网络理论中也有重要应用。张量图记号可以把这些概念直观地表示出来。

对于矩阵 A ，如果存在非零向量 v 和标量 λ 使得 $Av = \lambda v$ ，那么 λ 就称为 A 的一个特征值，而 v 是相应的特征向量。在张量图记号中，把它的特征分解写成 $A = Q\Lambda Q^{-1}$ 很方便，其中 Q 的列是 A 的特征向量， Λ 是由特征值组成的对角矩阵。因此：

$$-A- = -Q-\underset{\lambda}{\circ}-Q^{-1}- \quad (1.1)$$

矩阵的迹等于其特征值之和。我们可以用张量图表示这一关系：

$$\text{Tr}(A) = \text{A} = \text{Q}-\underset{\lambda}{\circ}-\text{Q}^{-1} = \text{Q}-\underset{\lambda}{\circ} = \underset{\lambda}{\circ} = \sum_i \lambda_i \quad (12)$$

1.7 对称与对称化

张量的一个常见性质是对称性。对矩阵来说，对称性意味着 $A^T = A$ 。对张量来说，则意味着交换其指标不会改变它的值。典型例子是协方差矩阵或 Hessian 矩阵，但某些高阶统计矩，比如三阶或四阶矩张量，也可能具有对称性。有时这种对称性只相对于某个特定群成立，但大多数时候是相对于边的所有置换成立。复制张量就是一个完全对称张量的简单例子。

有时我们会通过对所有指标置换求和来对张量进行对称化。我们用一条波浪线覆盖被对称化的边来表示：

$$\text{Z} = \text{=} + \text{X}, \quad \text{Z} = \text{=} + \text{X} + \text{X} + \text{X} + \text{X} + \text{X}$$

例如，如果 A 是一个方阵， $A + A^T = \text{Z}A = -A + \text{A}$ 。还有一个互补概念是反对称化（或斜对称化），此时我们对所有置换按适当符号求和。例如，一

个 2 阶斜对称矩阵 A 满足 $A_{ij} = -A_{ji}$ 。我们可以用一条扁平的粗线表示反对称化：
 $\text{---} \overbrace{A} \text{---} = -A - \text{---} \overbrace{A} \text{---}$ 。在更高阶的情形下，每一项的符号由置换的奇偶性决定。

这两种张量都是幂等的，因为对一个已经对称的张量再做对称化不会改变它：

$$\text{---} \overbrace{\text{---} \overbrace{A} \text{---}} \text{---} = \text{---} \overbrace{A} \text{---}, \quad \text{---} \overbrace{\text{---} \overbrace{\text{---} \overbrace{A} \text{---}} \text{---}} \text{---} = \text{---} \overbrace{A} \text{---}.$$

1.8 协变与逆变

在物理学中，经常需要在不同坐标系之间变换。这类变换往往会以不同方式作用在矩阵的左侧和右侧，也会类似地作用于行向量和列向量。对于张量，这就推广为协变与逆变的概念。借助这些概念，我们需要跟踪“输入”和“输出”向量。我们还需要区分诸如单位矩阵 $\text{---} \circ \text{---}$ 、 $\succ$, and $\prec$ 。

这个概念让我们可以通过把输入边连接到输出边，像处理矩阵和向量那样在一定程度上“代数地”组合张量。不过，对更复杂的张量来说，我们需要知道具体该连接哪些边，而这时指标记号更有用。

在计算机科学和机器学习中，协变与逆变的概念通常并不实用，所以本书不会使用它。

1.9 练习

练习 1. 给定一系列矩阵 $A_1, A_2, \dots, A_n \in \mathbb{R}^{n \times n}$ ，以及向量 $v_1, v_2, \dots, v_n \in \mathbb{R}^n$ ，请用张量图画出由向量 $A_1 v_1, A_2 v_2, \dots, A_n v_n$ 组成的矩阵。

练习 2. 用张量图表示两个矩阵的 Hadamard 积（逐元素乘法）。它与普通矩阵乘法有何不同？（关于这一点，见 ??。）

练习 3. 用张量图表示矩阵 $A = U \Sigma V^T$ 的 SVD。这与特征分解的图示相比如何？如何把它推广到高阶张量？（在第 ?? 节我们会看到更多内容。）

第二章 统计与概率

2.1 矩的定义

设 $x \in \mathbb{R}^n$ 是一个随机变量。我们记 $m = E[x] \in \mathbb{R}^n$ 为期望，记 $M = \text{Var}[x] = E[(x - m)(x - m)^T]$ 为协方差（当这些量有定义时）。

在张量图中，我们会使用方括号：

$$-m = [-x] \quad \text{和} \quad -M- = [-(x \ominus m) \quad (x \ominus m)-]$$

我们使用带圈减号 $\ominus$ ，以便把这个操作和缩并边区分开来。

我们还可以定义三阶和四阶中心矩张量：

$$M_3 \begin{smallmatrix} \diagup \\ \diagdown \end{smallmatrix} = \begin{bmatrix} (x \ominus m)- \\ (x \ominus m)- \\ (x \ominus m)- \end{bmatrix} \quad \text{和} \quad M_4 \begin{smallmatrix} \diagup \\ \diagdown \end{smallmatrix} = \begin{bmatrix} (x \ominus m)- \\ (x \ominus m)- \\ (x \ominus m)- \\ (x \ominus m)- \end{bmatrix}.$$

2.1.1 线性组合的期望

一般原则：“期望的线性性”允许你把图中所有不涉及 X 的部分提出去。

$$\left[\begin{array}{ccccc} A & & X & - & B & & C \\ | & \diagup & | & & \diagdown & & | \\ X & - & D & - & X & - & E \end{array} \right] = \begin{array}{ccccc} A & & X & - & B & & C \\ | & \diagup & | & & \diagdown & & | \\ \boxed{X} & - & \boxed{D} & - & \boxed{X} & - & E \end{array} = \begin{array}{c} A \quad \bigcap \quad B \quad C \\ \quad \quad \quad \diagdown \quad \diagup \quad \diagdown \\ \quad \quad \quad D \quad M_3 \quad E \end{array}$$

其中 M_3 是期望¹ $\left[\begin{smallmatrix} | & | & | \\ \diagdown & \diagup & \diagdown \end{smallmatrix} \right]$ ，它是一个 9 阶张量，并且不依赖常量 A 、 B 、 C 和 D 。在实践中，你会想给边命名，以便追踪哪些对象与哪些对象相乘。

¹FIXME: 这与刚刚引入的记号不同。

我们甚至可以利用期望的线性性，把期望推进到张量的无穷和内部；如下矩生成函数把所有 M_k 张量联系起来：

$$\begin{aligned} E(e^{\langle x \ominus m, t \rangle}) &= \sum_{k=0}^{\infty} \frac{1}{k!} E[\langle x \ominus m, t \rangle^k] = E\left[\sum_{k=0}^{\infty} \frac{1}{k!} \langle (x \ominus m)^{\otimes k}, t^{\otimes k} \rangle\right] = \sum_{k=0}^{\infty} \frac{1}{k!} \langle M_k, t^{\otimes k} \rangle \\ &= 1 + \underset{m}{\overset{t}{|}} + \frac{1}{2} \underset{t}{\overset{t}{|}} M \underset{t}{\overset{t}{|}} + \frac{1}{6} \underset{t}{\overset{t}{|}} M_3 \underset{t}{\overset{t}{|}} + \frac{1}{24} \underset{t}{\overset{t}{|}} M_4 \underset{t}{\overset{t}{|}} + \dots \end{aligned}$$

2.1.2 线性形式

《Matrix Cookbook》给出了下面这个简单的期望：

$$E[AXB + C] = AE[X]B + C \quad \begin{bmatrix} -A-X-B- \\ + -C- \end{bmatrix} = \begin{matrix} -A-[X]-B- \\ + -C- \end{matrix} \quad (312)$$

2.1.3 二次型

我们常常更愿意用简单的中心矩来写期望；这可以通过提出均值来做到：

$$\begin{bmatrix} x- \\ x- \end{bmatrix} = \begin{bmatrix} (x \ominus m)- \\ (x \ominus m)- \end{bmatrix} + \begin{matrix} m- \\ m- \end{matrix} = M \begin{matrix} \prec \\ \prec \end{matrix} + \begin{matrix} m- \\ m- \end{matrix}$$

这样就很容易处理《Matrix Cookbook》中的二次型：

$$\begin{aligned} \text{Var}[Ax] &= A \text{Var}[x] A^T \quad \begin{bmatrix} A-x \ominus [A-x] \\ A-x \ominus [A-x] \end{bmatrix} = \begin{bmatrix} A-(x \ominus m) \\ A-(x \ominus m) \end{bmatrix} \\ &= \begin{matrix} A- \\ A- \end{matrix} \begin{bmatrix} (x \ominus m) \\ (x \ominus m) \end{bmatrix} \\ &= -A-M_2-A- \end{aligned} \quad (313)$$

$$\begin{aligned} E[x^T Ax] &= \text{Tr}(AM) + m^T A m \quad [x-A-x] = \left(\begin{bmatrix} (x \ominus m)- \\ (x \ominus m)- \end{bmatrix} + \begin{matrix} m- \\ m- \end{matrix} \right) \begin{matrix} \succ A \\ \succ A \end{matrix} \\ &= \begin{bmatrix} (x \ominus m) \\ (x \ominus m) \end{bmatrix} \begin{matrix} \succ A \\ \succ A \end{matrix} + \begin{matrix} m \succ A \\ m \succ A \end{matrix} \end{aligned} \quad (318)$$

$$= \overbrace{M-A} + m-A-m$$

$$E[(A\mathbf{x} + a)(B\mathbf{x} + b)^T] = AMB^T + (Am + a)(Bm + b)^T \quad (320)$$

$$E[\mathbf{x}\mathbf{x}^T] = M + mm^T \quad (321)$$

$$E[\mathbf{x}a^T\mathbf{x}] = (M + mm^T)a \quad (322)$$

$$E[\mathbf{x}^T a\mathbf{x}^T] = a^T(M + mm^T) \quad (323)$$

$$E[(A\mathbf{x})(A\mathbf{x})^T] = A(M + mm^T)A^T \quad (324)$$

$$E[(\mathbf{x} + a)(\mathbf{x} + a)^T] = M + (m + a)(m + a)^T \quad (325)$$

$$E[(A\mathbf{x} + a)^T(B\mathbf{x} + b)] = \text{Tr}(AMB^T) + (Am + a)^T(Bm + b) \quad (326)$$


$$E[\mathbf{x}^T\mathbf{x}] = \text{Tr}(M) + m^T m \quad (327)$$

$$E[\mathbf{x}^T A\mathbf{x}] = \text{Tr}(AM) + m^T Am \quad (328)$$

$$E[(A\mathbf{x})^T(A\mathbf{x})] = \text{Tr}(AMA^T) + (Am)^T(Am) \quad (329)$$

$$E[(\mathbf{x} + a)^T(\mathbf{x} + a)] = \text{Tr}(M) + (m + a)^T(m + a) \quad (330)$$

2.1.4 三次型



当 x 是均值向量为 m 的随机向量时，把原始三阶矩展开为中心矩会很方便：

$$\begin{aligned} \begin{bmatrix} x- \\ x- \\ x- \end{bmatrix} &= \begin{bmatrix} (x \ominus m)- \\ (x \ominus m)- \\ (x \ominus m)- \end{bmatrix} + 3 \begin{bmatrix} (x \ominus m)- \\ m- \\ m- \end{bmatrix} + 3 \begin{bmatrix} m- \\ (x \ominus m)- \\ (x \ominus m)- \end{bmatrix} + \begin{bmatrix} m- \\ m- \\ m- \end{bmatrix} \\ &= \overset{|}{\underset{\diagup \diagdown}{M_3}} + 3 \begin{matrix} m- \\ -M- \end{matrix} + \begin{matrix} m- \\ m- \\ m- \end{matrix} \end{aligned}$$

TODO: m, M 项中的边需要做对称化。

但这仍然有些杂乱。另见下面关于累积量的内容。

假设 $\mathbf{x}$ 是一个坐标相互独立的随机向量，均值为 m ，协方差为 M ，中心矩为 $v_3 = \mathbb{E}[(\mathbf{x} - m)^3]$ 。那么（见 [7]）

$$\begin{aligned}
 & \mathbb{E}[(A\mathbf{x} + a)(B\mathbf{x} + b)^T(C\mathbf{x} + c)] \\
 &= A \operatorname{diag}(B^T C) v_3 \\
 &+ (Am + a) \operatorname{Tr}(BMC^T) \\
 &+ AMC^T(Bm + b) \\
 &+ AMB^T(Cm + c) \\
 &+ (Am + a)(Bm + b)^T(Cm + c) \\
 &\mathbb{E}[\mathbf{xx}^T \mathbf{x}] \\
 &= v_3 \\
 &+ 2Mm \\
 &+ (\operatorname{Tr}(M) + m^T m)m
 \end{aligned}$$

2.2 累积量

给定随机向量 $x \in \mathbb{R}^d$ ，它的 n 阶累积量张量 $K_n \in \mathbb{R}^{d, \dots, d}$ 定义为

$$\log \mathbb{E}(e^{\langle t, x \rangle}) = \sum_{n=1}^{\infty} \frac{1}{n!} \langle K_n, t^{\otimes n} \rangle = \frac{t}{K_1} + \frac{1}{2} \frac{t}{K_2} + \frac{1}{6} \frac{t}{t' \backslash t} + \dots$$

前几个累积量类似于中心矩：

$$K_1 = m \quad \text{和} \quad K_2 = M \quad \text{和} \quad K_3 = M_3 \quad \text{和} \quad K_4 = M_4 - \frac{-M_2-}{-M_2-} - \frac{\backslash M_2}{\backslash M_2} - \frac{\backslash M_2}{\backslash M_2} \frac{\backslash}{\backslash}.$$

它们有一个很好的性质（从定义很容易看出）：对于独立随机变量，累积量是可加的： $K_n(x+y) = K_n(x) + K_n(y)$ 。这推广了一个标准性质：独立随机变量之和的方差等于方差之和。

我们可以用累积量来写出 $x^{\otimes n}$ 的期望：

$$\left[\begin{array}{c} x \quad x \\ x \\ | \end{array} \right] = \frac{\backslash K_3}{|} + \frac{\backslash K_2}{K_1} + \frac{\backslash K_2}{K_1} + \frac{\backslash K_1}{K_2} + \frac{\backslash K_1}{K_1} \frac{\backslash K_1}{K_1}.$$

一般而言，求和遍历集合 $\{1, \dots, n\}$ 的所有划分。

如果 x 的各个分量相互独立, 累积量张量 $K_1, K_2, \dots$ 的非对角项为零。这意味着可以按如下方式写出: 假设每个 x_i 的累积量为 $\kappa_1, \kappa_2, \kappa_3, \kappa_4 \in \mathbb{R}$, 则

$$\begin{aligned} \begin{bmatrix} x & x \\ x & x \end{bmatrix} &= \kappa_4 \text{ (four-point star)} \\ &+ \kappa_3 \kappa_1 \left(\text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} \right) \\ &+ \kappa_2^2 \left(\text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} \right) \\ &+ \kappa_2 \kappa_1^2 \left(\text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} \right) \\ &+ \kappa_1^4 \text{ (four-point star)} \end{aligned}$$

特别注意, 如果均值 κ_1 为零, 就只剩下四项。当 $n = 5$ 时, 总共有 52 个划分; 但若 $\kappa_1 = 0$, 只有 11 项保留下来:

$$\kappa_5 \text{ (five-point star)} + \kappa_3 \kappa_2 \left(\text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} \right)$$

如果 x 是高斯变量, 所有 3 阶及更高阶累积量都为零。当 $n = 6$ 时, 总共有 203 个划分, 但 $E[x^{\otimes 6}]$ 只剩 15 项²:

$$\begin{aligned} &\kappa_2^3 \left(\text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} \right. \\ &\quad \left. + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} + \text{ (two-point star)} \right). \end{aligned}$$

2.2.1 四次型

我们可以用它来计算 $\text{Var}[x^T A x]$ 。假设 A 是对称的:

$$\begin{aligned} \text{Var}[x^T A x] &= \begin{bmatrix} x & A & x \\ x & A & x \end{bmatrix} - \begin{bmatrix} x & A & x \\ x & A & x \end{bmatrix} \\ &= \kappa_4 A \text{ (four-point star)} + 4\kappa_3 \kappa_1 A \text{ (two-point star)} - A \text{ (two-point star)} \\ &\quad + 2\kappa_2^2 \text{ (two-point star)} + \kappa_2^2 \text{ (two-point star)} \\ &\quad + 4\kappa_2 \kappa_1^2 \text{ (two-point star)} - A \text{ (two-point star)} + 2\kappa_2 \kappa_1^2 \text{ (two-point star)} - A \text{ (two-point star)} \\ &\quad + \kappa_1^4 \text{ (two-point star)} - A \text{ (two-point star)} - A \text{ (two-point star)} \\ &\quad - \left(\kappa_2 \text{ (two-point star)} + \kappa_1^2 \text{ (two-point star)} \right)^2 \\ &= 2\kappa_2^2 \text{ (two-point star)} + 4\kappa_2 \kappa_1^2 \text{ (two-point star)} - A \text{ (two-point star)} \\ &\quad + 4\kappa_3 \kappa_1 A \text{ (two-point star)} - A \text{ (two-point star)} + \kappa_4 A \text{ (four-point star)} \end{aligned}$$

²这就是为什么对 $g \sim N(0, 1)$ 有 $E[g^6] = 15$ 。

《Matrix Cookbook》把它列为

$$\text{Var}[x^T A x] = 2\mu_2^2 \text{Tr}(A^2) + 4\mu_2 c^T A^2 c + 4\mu_3 c^T A a + (\mu_4 - 3\mu_2^2) a^T a \quad (319)$$

其中 $c = \mu_1$ 是 x 的均值, $a = \text{diag}(A)$ 是 A 的对角线, 而 $\mu_4 = \kappa_4 + 3\kappa_2^2$ 是四阶中心矩。

2.3 加权标量变量

令 $y = w^T x$, 并令 $m = E[y]$, 则

$$E[y] = m = w^T \mu \quad (321)$$

$$E[(y \ominus m)^2] = w - M_2 - w \quad (322)$$

$$E[(y \ominus m)^3] = w - \overset{w}{\underset{w}{M_3}} - w \quad (323)$$

$$E[(y \ominus m)^4] = w - \overset{w}{\underset{w}{M_4}} - w \quad (324)$$

对于 $x \sim N(0, 1)$, 有不等式:

$$E[y^n]^{1/n} \leq \sqrt{2/\pi} \|w\|_2.$$

2.4 高斯矩

对于高斯向量 $x \sim \mathcal{N}(m, M)$: - 所有奇数阶中心矩都为零: $M_3 = 0$, 等等。 - 偶数阶矩可以通过 Isserlis 定理计算。

例如:

$$\mathbb{E}[(x \ominus m)^{\otimes 4}] = M \otimes M + M \otimes M + \dots$$

(对指标的不同配对求和)。

2.4.1 高斯分部积分

如果 X 是一个由高斯条目组成、均值为零且带有某个协方差的张量, 那么对任意可微函数 f , Stein 引理给出下面这个非常一般的方程:

结合第 ?? 章中的张量链式法则，这可以成为求解许多困难期望的强大方法。

$$E(xx^T) = \Sigma + mm^T \quad (377)$$

$$E[x^T Ax] = \text{Tr}(A\Sigma) + m^T Am \quad (378)$$

$$\begin{aligned} \text{Var}(x^T Ax) &= \text{Tr}[A\Sigma(A + A^T)\Sigma] + \dots \\ &\quad + m^T(A + A^T)\Sigma(A + A^T)m \end{aligned} \quad (379)$$

$$E[(x - m')^T A(x - m')] = (m - m')^T A(m - m') + \text{Tr}(A\Sigma) \quad (380)$$

如果 $\Sigma = \sigma^2 I$ 且 A 对称，则

$$\text{Var}(x^T Ax) = 2\sigma^4 \text{Tr}(A^2) + 4\sigma^2 m^T A^2 m \quad (381)$$

假设 $x \sim \mathcal{N}(0, \sigma^2 I)$ ，且 A 和 B 对称，则

$$\text{Cov}(x^T Ax, x^T Bx) = 2\sigma^4 \text{Tr}(AB) \quad (382)$$

2.4.2 三次型

假设 x 是一个坐标相互独立的随机向量，均值为 m ，协方差为 M ：

$$\begin{aligned} E[xb^T xx^T] &= mb^T(M + mm^T) + (M + mm^T)bm^T \\ &\quad + b^T m(M - mm^T) \end{aligned} \quad (383)$$

2.4.3 四次型的均值

$$\begin{aligned} E[xx^T xx^T] &= 2(\Sigma + mm^T)^2 + m^T m(\Sigma - mm^T) \\ &\quad + \text{Tr}(\Sigma)(\Sigma + mm^T) \end{aligned}$$

$$\begin{aligned} E[xx^T Axx^T] &= (\Sigma + mm^T)(A + A^T)(\Sigma + mm^T) \\ &\quad + m^T Am(\Sigma - mm^T) + \text{Tr}[A\Sigma](\Sigma + mm^T) \end{aligned}$$

$$E[x^T xx^T x] = 2\text{Tr}(\Sigma^2) + 4m^T \Sigma m + (\text{Tr}(\Sigma) + m^T m)^2$$

$$\begin{aligned} E[x^T A x x^T B x] &= \text{Tr}[A \Sigma (B + B^T) \Sigma] + m^T (A + A^T) \Sigma (B + B^T) m \\ &\quad + (\text{Tr}(A \Sigma) + m^T A m)(\text{Tr}(B \Sigma) + m^T B m) \end{aligned}$$

$$\begin{aligned} E[a^T x b^T x c^T x d^T x] &= (a^T (\Sigma + m m^T) b)(c^T (\Sigma + m m^T) d) \\ &\quad + (a^T (\Sigma + m m^T) c)(b^T (\Sigma + m m^T) d) \\ &\quad + (a^T (\Sigma + m m^T) d)(b^T (\Sigma + m m^T) c) - 2a^T m b^T m c^T m d^T m \end{aligned}$$

$$\begin{aligned} E[(Ax + a)(Bx + b)^T (Cx + c)(Dx + d)^T] &= [A \Sigma B^T + (Am + a)(Bm + b)^T][C \Sigma D^T + (Cm + c)(Dm + d)^T] \\ &\quad + [A \Sigma C^T + (Am + a)(Cm + c)^T][B \Sigma D^T + (Bm + b)(Dm + d)^T] \\ &\quad + (Bm + b)^T (Cm + c)[A \Sigma D^T - (Am + a)(Dm + d)^T] \\ &\quad + \text{Tr}(B \Sigma C^T)[A \Sigma D^T + (Am + a)(Dm + d)^T] \end{aligned}$$

$$\begin{aligned} E[(Ax + a)^T (Bx + b)(Cx + c)^T (Dx + d)] &= \text{Tr}[A \Sigma (C^T D + D^T C) \Sigma B^T] \\ &\quad + [(Am + a)^T B + (Bm + b)^T A] \Sigma [C^T (Dm + d) + D^T (Cm + c)] \\ &\quad + [\text{Tr}(A \Sigma B^T) + (Am + a)^T (Bm + b)][\text{Tr}(C \Sigma D^T) + (Cm + c)^T (Dm + d)] \end{aligned}$$

见 [7]。

2.4.4 高斯混合

对于高斯混合：

$$x \sim \sum_k \pi_k \mathcal{N}(m_k, M_k),$$

矩是加权和：

$$E[x] = \sum_k \pi_k m_k, \quad \text{Var}[x] = \sum_k \pi_k (M_k + m_k m_k^T) - \left(\sum_k \pi_k m_k \right) \left(\sum_k \pi_k m_k \right)^T.$$

高阶矩也类似地通过线性组合。

$$E[x] = \sum_k \rho_k m_k \quad (384)$$

$$\text{Cov}(x) = \sum_k \sum_{k'} \rho_k \rho_{k'} (\Sigma_k + m_k m_k^T - m_k m_{k'}^T) \quad (385)$$

2.4.5 导数

矩关于 m 或 M 的导数可以通过在积分号下求导得到；在高斯情形下，还可以使用 Stein 引理。

2.5 向量与张量的自由概率

自由概率理论提供了经典概率的非交换类比。我们将从最简单的情形开始，即条目为标量的向量；然后推进到矩阵，最后到更高阶张量。

2.5.1 向量的自由累积量

对于条目为标量的随机向量 $x \in \mathbb{R}^n$ ，自由累积量的定义类似于经典累积量，但只使用非交叉划分。

向量的 R-变换

R-变换（自由累积量生成函数）为：

$$R_x(z) = \sum_{n=1}^{\infty} \kappa_n^{\text{free}} z^{n-1}$$

这是经典累积量生成函数 $\log E[e^{tz}] = \sum_{n=1}^{\infty} \frac{\kappa_n}{n!} t^n$ 的自由概率对应物。

矩-累积量关系

如果每个 x_i 的自由累积量为 $\kappa_1^{\text{free}}, \kappa_2^{\text{free}}, \kappa_3^{\text{free}}, \kappa_4^{\text{free}} \in \mathbb{R}$, 则:

$$\begin{bmatrix} x & x \\ x & x \end{bmatrix}_{\text{free}} = \begin{aligned} & + \kappa_3^{\text{free}} \kappa_1^{\text{free}} \left(\text{diagram 1} \right) \\ & + (\kappa_2^{\text{free}})^2 \left(\text{diagram 2} \right) \\ & + \kappa_2^{\text{free}} (\kappa_1^{\text{free}})^2 \left(\text{diagram 3} \right) \\ & + (\kappa_1^{\text{free}})^4 \left(\text{diagram 4} \right) \end{aligned}$$

红色 = 交叉划分 (在自由概率中排除)

与经典情形相比: 15 个划分 $\rightarrow$ 9 个非交叉划分!


2.5.2 矩阵的自由累积量

对于随机矩阵, 我们必须考虑乘积的迹。与标量不同, 矩阵乘积不满足交换律, 这增加了复杂性。

$$\text{经典累积量: } E[X^3] = \kappa_3 + 3\kappa_2\kappa_1 + \kappa_1^3 \quad (5 \text{ 个划分})$$

$$\text{自由累积量: } E[\text{Tr}(X^3)] = \kappa_3^{\text{free}} + \kappa_1^{\text{free}} \kappa_2^{\text{free}} \quad (2 \text{ 个 NC 划分})$$

划分 (1, 3), (2) 是交叉的, 因此在自由概率中被排除:



关键洞见: 对矩阵来说, 元素之间只有一条边需要匹配。对更高阶张量来说, 则有多条边 (颜色) 需要匹配。

2.5.3 张量自由累积量

对于 D 阶张量, 由于有彩色非交叉划分, 自由累积量理论变得更加丰富。

张量的彩色非交叉划分

对于 D 阶张量, 每个元素有 D 条“腿”或指标。一个有效配对必须:

- 当元素排在圆周上时是非交叉的
- 在被配对元素之间匹配全部 D 种颜色 (每条腿一种)

这会大幅减少有效划分的数量。对于 3 阶张量:

矩阵: $\boxed{X} \overset{1 \text{ 条边}}{\text{---}} \boxed{X}$ 3 阶张量: $\boxed{T} \overset{3 \text{ 条边}}{\text{---}} \boxed{T}$

张量的不变量迹

不同于矩阵, 高阶张量没有唯一的标准迹。相反, 每一种把张量缩并成标量的方式都会定义一个不同的不变量:

矩阵 ($D = 2$)	张量 ($D > 2$)
唯一不变量 $\text{Tr}(X_1 \cdots X_n)$	不变量族 $\text{Tr}_\pi(T_1, \dots, T_n)$ 由彩色置换 $\pi \in \mathfrak{S}_{Dn}$ 索引

Tr_π 的定义: 给定张量 $T_1, \dots, T_n$, 每个张量都有 D 条腿 (颜色从 1 到 D), 彩色置换 $\pi = (\pi^{(1)}, \dots, \pi^{(D)}) \in \mathfrak{S}_n^D$ 指定哪些腿相连:

$\text{Tr}_\pi(T_1, \dots, T_n) =$ 例子:

对于矩阵 ($D = 2$), 只有循环置换会给出非零迹, 从而恢复通常的 $\text{Tr}(X_1 X_2 \cdots X_n)$ 。

归一化: 为了在 $N \rightarrow \infty$ 时得到有限极限, 我们用 $N^{-(D-1)n}$ 归一化:

$$\frac{1}{N^{(D-1)n}} \text{Tr}_\pi(T_1, \dots, T_n) \xrightarrow{N \rightarrow \infty} \text{finite}$$

矩-累积量公式

张量的矩-累积量关系涉及所有不变量迹：

$$\left(\mathbb{E}[\text{Tr}_\pi(T_{i_1}, \dots, T_{i_n})] \right)_{\pi \in \text{NC}_D(n)} = \sum_{\sigma \in \text{NC}_D(n)} \kappa_\sigma^{(t)} \cdot (\text{pattern matching})$$

这些矩形成一个由彩色非交叉置换索引的向量，而张量自由性作用在整个族上。

$n = 2$ 的例子：二阶矩分解为

$$\mathbb{E}[\text{Tr}(T_1 T_2)] = \kappa_2^{(t)} \begin{array}{c} \textcircled{1} \\ \textcircled{2} \end{array} \delta_{i_1, i_2} + (\kappa_1^{(t)})^2 \begin{array}{c} \textcircled{1} \\ \textcircled{2} \end{array}$$

对于高斯张量， $\kappa_1^{(t)} = 0$ 且当 $n > 2$ 时 $\kappa_n^{(t)} = 0$ ，因此：

$$\mathbb{E}[\text{Tr}(T_1 T_2)] = \kappa_2^{(t)} \delta_{i_1, i_2} = \delta_{i_1, i_2}$$

2.5.4 张量 Wick 定理


对于高斯张量，一个类似 Wick 定理的基本结果成立：

张量 Wick 分解：设 $(T_i)_{i \in I}$ 是大小为 N 的独立同分布标准高斯 D 腿张量。当 $N \rightarrow \infty$ 时：

$$\mathbb{E}[T_{i_1} \cdots T_{i_{2k}}] = \sum_{\pi \in \text{NC}_D(2k)} \prod_{(j, j') \in \pi} \delta_{i_j, i_{j'}} + O(N^{-1})$$

这说明高斯张量渐近张量自由，并且二阶以上的所有累积量都消失。

对于四个 3 阶张量, 有效的彩色非交叉配对受到严格限制:



2.5.5 张量自由性下的可加性

如果两个张量代数 $\mathcal{A}_1$ 和 $\mathcal{A}_2$ 是张量自由的, 那么对 $A \in \mathcal{A}_1$ 和 $B \in \mathcal{A}_2$ 有:

$$\kappa_n^{(t)}(A+B) = \kappa_n^{(t)}(A) + \kappa_n^{(t)}(B)$$

这推广了独立变量的经典累积量可加性。

图示地看, 对于二阶累积量 (协方差):

$$\kappa_2^{(t)}\left(\begin{array}{c} \boxed{A} \\ \boxed{B} \end{array}\right) = \kappa_2^{(t)}\boxed{A} + \kappa_2^{(t)}\boxed{B}$$

混合累积量消失

对于矩阵, 如果 A 和 B 自由且其中一个迹为零, 那么交替乘积满足 $\kappa_n^{\text{free}}(AB \cdots) = 0$ 。对于张量, 类似性质取决于缩并模式。

定义: 如果 $\kappa_1^{(t)}(T) = 0$, 则称张量 T 具有零一阶累积量; 这意味着对所有彩色置换 $\pi \in \mathfrak{S}_D$, 都有 $E[\text{Tr}_\pi(T)] = 0$ 。

定义: 交替缩并模式是连接序列 $A_1, B_1, A_2, B_2, \dots$ 中张量的一种方式, 其中:


- 张量以交替顺序出现 ($A, B, A, B, \dots$)

- 每个张量的腿都与相邻张量缩并（没有张量孤立）
- 缩并尊重张量结构

定理：如果 A 和 B 张量自由，且 $\kappa_1^{(t)}(A) = 0$ ，那么任意交替缩并的累积量都为零：

$$\kappa_n^{(t)}(A \otimes_C B \otimes_C A \otimes_C \cdots) = 0 \quad \text{for } n \geq 2$$

3 阶张量的交替缩并示例：



如果 $\kappa_1^{(t)}(A) = 0$ ，这些缩并都会给出 $\kappa_n^{(t)} = 0$ 。

这是因为任意非交叉划分都必须包含一个含有 A 的单元素块，但 $\kappa_1^{(t)}(A) = 0$ 。

与矩阵的关键差异在于：对于张量，我们必须指定缩并模式，因为即使是同一批张量，不同缩并也可能产生不同结果。

2.5.6 张量 Wishart 矩阵的谱

考虑一个 3 阶张量 $T \in \mathbb{C}^{N \times N \times N}$ ，其条目为独立同分布的高斯变量 $\mathcal{N}_{\mathbb{C}}(0, N^{-3})$ 。Wishart 型矩阵 $W = TT^\dagger$ （缩并一个指标）具有如下极限谱分布：

$$\boxed{T} \quad \boxed{T^\dagger} \xrightarrow{\text{MP}(1) \boxtimes \text{MP}(1)} \text{MP}(1/2)$$

其中 $\boxtimes$ 表示自由乘性卷积， $\text{MP}(c)$ 是 Marchenko-Pastur 分布。

2.5.7 张量网络与自由概率

自由概率为分析张量网络态提供了强大工具，而张量网络态自然出现在量子多体物理和机器学习中。

图 amalgamation (合并)


对于图 $G = (V, E)$ 上的张量网络, 如果每个顶点放置随机高斯张量, 则边界密度矩阵会按照图结构分解:

图 amalgamation (合并): 令 ρ_b 为随机张量网络的边界密度矩阵。则:

$$\rho_b = \bigstar_{\gamma \in \mathcal{C}_{\min}} \rho_\gamma$$

其中 $\bigstar_{\mathcal{B}}$ 表示在边界代数上的带 amalgamation (合并) 的自由乘性卷积, $\mathcal{C}_{\min}$ 是 G 的最小割。

例如, 一个简单的双顶点网络:

**纠缠与最大流**


张量网络态的 Rényi 熵与网络图上的最大流问题相联系:

$$S_q(\rho_b) = \frac{1}{1-q} \log \left[\max_f \prod_{e \in E} w_e^{f(e)} \right] + o(1)$$

其中 f 遍历整数流, w_e 是边权。对于最大纠缠连接 ($w_e = 1$), 这会恢复全息理论中的 Ryu-Takayanagi 公式。

2.5.8 高阶张量示例**星形网络**


考虑一个星形图, 其中有一个度数为 $D = 4$ 的中心顶点:



边界密度矩阵是 $\rho_b = W_1 W_2 W_3 W_4$, 其中包含独立的 Wishart 因子。由张量自由性可得:


$$\mu_\rho = \text{MP}(1)^{\boxtimes 4}, \quad R_\rho(w) = \frac{4w}{1-w}$$

每个格点的 von Neumann 熵等于 $\log 4 - 3/4$ 。
自由积分解为：




梯形网络

对于带周期竖直边界的 $2 \times L$ 梯形网络：



纠缠熵按 $S_2 = \lceil L/2 \rceil \log N + O(1)$ 缩放，表现出面积律缩放。
穿过网络的最大流为：



2.5.9 D 元 Catalan 数

$\text{NC}_D(n)$ 的彩色 Möbius 函数涉及 D 元 Catalan 数：

$$\mu_{\text{col}}(0_n, 1_n) = (-1)^{n-1} C_{n-1}^{(D)}$$

其中 $C_n^{(D)} = \frac{1}{(D-1)n+1} \binom{Dn}{n}$ 是 Fuss-Catalan 数。
 D 元 Catalan 数的增长：

n	$C_n^{(2)}$	$C_n^{(3)}$	$C_n^{(4)}$
0	1	1	1
1	2	3	5
2	5	12	35
3	14	55	285

当 $D = 2$ (矩阵) 时，我们恢复标准 Catalan 数。对于 $D = 3$ (3 阶张量)：

$$C_0^{(3)} = 1, \quad C_1^{(3)} = 1, \quad C_2^{(3)} = 3, \quad C_3^{(3)} = 12, \quad C_4^{(3)} = 55, \dots$$

2.5.10 Melon 型图


Melonic diagrams (melon 型图) 是张量模型的 $1/N$ 展开中的主导阶 Feynman 图。它们得名于类似 melon 的形状，并具有特殊的拓扑结构。

定义与结构

对于 D 阶张量，melon 型图是可以画在 2-球面上的图，并满足：


- 每个面由 D 种颜色之一着色
- 图具有由 “melons” 组成的树状结构
- 任意顶点周围没有颜色重复出现

3 阶张量的基本 melon (2 点函数)：



高阶 melon 型图

4 点 melon 型图 (N^{-1} 阶)：




计数 melon 型图

melon 型图的数量增长远慢于一般图：

Melonic 主导性：在 $1/N$ 展开的 n 阶：

- 一般图： $\sim (D!)^n n!$
- Melon 型图： $\sim D^n \cdot C_{n-1}$ (Catalan 数)

对于 3 阶张量的 3 阶项:



Melonic 普适性

在大 N 极限下, 张量模型由 melon 型图主导, 这会导致:

- 谱维数 $d_s = 2$ (类似分支聚合物)
- 当 $D \geq 3$ 时, 临界指数与 D 无关
- 与物理中的 Sachdev-Ye-Kitaev (SYK) 模型相联系

这种普适性正是 melon 型图在理解张量模型及其连续极限时处于核心地位的原因。

2.6 练习

练习 4.

$$\begin{aligned} E[(A\mathbf{x} + a)(A\mathbf{x} + a)^T(A\mathbf{x} + a)] &= A \text{diag}(A^T A) v_3 \\ &+ [2AM A^T + (A\mathbf{x} + a)(A\mathbf{x} + a)^T](Am + a) \\ &+ \text{Tr}(AM A^T)(Am + a) \end{aligned}$$

$$\begin{aligned} E[(A\mathbf{x} + a)b^T(C\mathbf{x} + c)(D\mathbf{x} + d)^T] &= (A\mathbf{x} + a)b^T(CMD^T + (Cm + c)(Dm + d)^T) \\ &+ (AMC^T + (Am + a)(Cm + c)^T)b(Dm + d)^T \\ &+ b^T(Cm + c)(AMD^T - (Am + a)(Dm + d)^T) \end{aligned}$$

练习 5. 在 Matrix Reference Manual 中寻找更多恒等式, 并尝试证明它们。也请尝试用 Tensorgrad 验证你的推导。

练习 6. 对于带彩色腿 (cyan、magenta、yellow) 的 3 阶张量 T_1, T_2, T_3 , 画出 $\{1, 2, 3\}$ 的所有有效 3 色非交叉划分。与集合划分总数相比, 它们有多少个?

练习 7. 考虑一个 4 阶高斯张量 $T \in \mathbb{R}^{N \times N \times N \times N}$ 。计算 $E[\text{Tr}_{12}(T)\text{Tr}_{34}(T)]$, 其中 Tr_{ij} 表示对指标 i 和 j 的缩并。使用张量 Wick 定理, 并画出相应的彩色图。

练习 8. 对于深度为 d 的二叉树上的张量网络, 证明边界纠缠熵按 $S \sim d \log N$ 缩放。使用图 amalgamation 定理, 并找出最小割。

练习 9. 验证对于 D 阶张量, n 阶 melon 型图的数量按 $D^n n!$ 增长。画出 $D = 3, n = 3$ 时的所有 melon 型图。

练习 10. 证明 D 元 Catalan 数满足递推式:

$$C_n^{(D)} = \sum_{k=0}^{n-1} C_k^{(D)} C_{n-1-k}^{(D-1)}$$

这对彩色非交叉划分的结构意味着什么?

练习 11. 对于两个张量自由的 3 阶张量 A 和 B , 计算第三张量累积量 $\kappa_3^{(t)}(A + B)$ 。使用彩色划分图验证可加性性质。

第三章 机器学习应用

3.1 最小二乘

3.2 交叉熵损失的 Hessian 矩阵

3.3 卷积神经网络

3.4 Transformer / 注意力

3.5 张量草图

3.6 强化学习

在考虑不完全信息博弈时，我们尝试用一个低秩张量来近似每个玩家的策略。可以用张量草图来近似这个张量。基本上，这意味着选取一个随机向量外积，并将其乘到导数上。这应该会很快……

参考文献

- [1] John Aldrich. *The Origins of Mathematical Words: A Comprehensive Dictionary of Latin, Greek, and Arabic Roots*. Mathematical Association of America, 2010.
- [2] William Rowan Hamilton. *Lectures on Quaternions*. Hodges and Smith, 1853.

第四章 附录

这里包含一些证明，例如公式 524 或 571 的证明。这些证明相当长，但可以用来和图示证明作对比。